Aprendizagem de Máquina Prof. Tiago Buarque A. de Carvalho

Exercícios sobre Comparação de Classi cadores

Atenção: a palavra signi cativa é utilizada para indicar uma diferença grande o su ciente que é atestada através de um teste de hipótese.

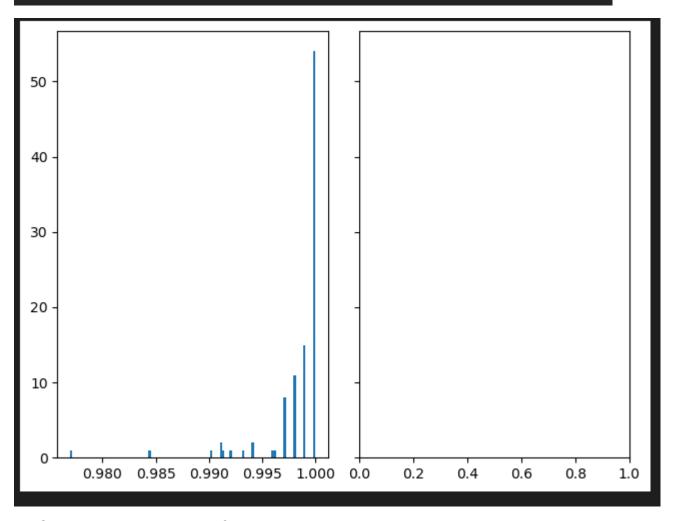
- (25 pontos) Realize 100-fold cross validation <u>estratificado</u> na base Skin Segmentation utilizando o classificador 1-NN com distância Euclidiana então realize os procedimentos abaixo.
 - (a) Mostre a média, o máximo e o mínimo da medida-F.

```
def calc f measure(classifier):
    list rates = []
    list f measure = []
    for train index, test index in skf.split(x,y):
       # TREINO
       x train = x[train index]
       y train = y[train index]
       # TESTE
        x \text{ test} = x[\text{test index}]
        y test = y[test index]
        classifier.fit(x train, y train)
        rate = classifier.score(x test, y test)
        list rates.append(rate)
        y pred = classifier.predict(x test)
        recall = recall score(y test, y pred)
        precision = precision score(y test, y pred)
        f measure = ((2*precision*recall)/(precision+recall))
        list f measure.append(f measure)
    average fMeasure = np.mean(list f measure)
    min fMeasure = min(list f measure)
    max fMeasure = max(list f measure)
    print("\n MÉDIA: \n")
    print("%.3f" % average fMeasure)
    print("\n MÁXIMO: \n")
    print("%.3f" % max fMeasure)
    print("\n MÍNIMO: \n")
    print("%.3f" % min fMeasure)
    return list f measure, average fMeasure
```

```
.
MÉDIA:
0.998
MÁXIMO:
1.000
MÍNIMO:
0.977
```

(b) Mostre o histograma da medida-F.

```
def histogram_f_measure(list_f_measure):
    n_bins = len(list_f_measure)
    fig, axs = plt.subplots(1, 2, sharey=True, tight_layout=True)
    axs[0].hist(list_f_measure, bins=n_bins)
```



(c) Calcule o intervalo de confiança da medida-F.

```
def calc_confidence_interval(average_fMeasure, list_f_measure):
    desvio_padrao = np.std(list_f_measure)

erro_padrao = desvio_padrao/np.sqrt(len(list_f_measure))

multiplier = abs(stats.distributions.norm.ppf(0.025))

confidence_interval = (average_fMeasure - multiplier*erro_padrao, average_fMeasure + multiplier*erro_padrao)
    print("\n INTERVALO DE CONFIANÇA \n")
    print(confidence_interval)

return confidence_interval
```

```
INTERVALO DE CONFIANÇA
(0.997643082377952, 0.9989729820531587)
```

(d) Qual a medida-F mínima que você espera ao aplicar este classi cador, sob as mesmas condições de treinamento, para dados nunca vistos?

O valor minimo do intervalo de confiança: 0.997643082377952

(e) Qual a medida-F esperada para o classi cador quando aplicada a dados nunca antes vistos.

A base Skin Segmentation (archive.ics.uci.edu/ml/datasets/Skin+Segmentation) tem três 4 colunas, as três primeiras são atributos e a última é a classe.

Valores dentro do intervalo de confiança: (0.997643082377952, 0.9989729820531587)

- 2. (25 pontos) Realize um experimento pareado com 100 repetições de Holdout 50/50 utilizando o classi cador 1-NN com distância Euclidiana. Utilize duas versões da base Wine archive. ics.uci.edu/ml/datasets/Wine para este experimento, a primeira versão é a base original, a segunda versão é a base sem a última coluna. Após calcular 100 taxas de acerto para cada uma das versões da base, realize os procedimentos abaixo.
 - (a) Calcule a diferença das 100 taxas de acerto.

Taxas:

```
0 [0.7415730337078652, 0.6966292134831461, 0.7191011235955056, 0.7191011235955056, 0.8202247191011236, 0.6653932584269663, 0.7640449438202247, 0.6629213483146667, 0.7415730337078652, 0.67415730337078652, 0.7752808988764045, 0.7752808988764045, 0.71572808988764045, 0.71572808988764045, 0.71572808988764045, 0.71572808988764045, 0.7157280898876404493, 0.79752808988764, 0.791011235955056, 0.7415730337078652, 0.7415730337078652, 0.7415730337078652, 0.7415730337078652, 0.74157303370786516854, 0.651685393258427, 0.8202247191011236, 0.70786516853932584, 0.791011235955056, 0.74157303370786516854, 0.6516853932584269663, 0.6853932584269663, 0.6853932584269663, 0.6853932584269663, 0.6853932584269663, 0.674157303370786516854, 0.6516859332584269663, 0.6853932584269663, 0.74157303370786516854, 0.6506292134831461, 0.696292134831461, 0.696292134831461, 0.797528089887640449, 0.7803370786516854, 0.6966292134831461, 0.797528089887649449, 0.7803370786516854, 0.7986516853932584269663, 0.74157303370786516854, 0.6966292134831461, 0.797528089887649449, 0.7803370786516854, 0.6966292134831461, 0.797528089887649449, 0.797528089887649449, 0.797528089887649449, 0.797528089887649449, 0.797528089887649449, 0.797528089887649449, 0.797528089887649449, 0.797528089887649449, 0.79752808988764949, 0.79752808988764949, 0.79752808988764949, 0.79752808988764949, 0.79752808988764949, 0.79752808988764949, 0.79752808988764949, 0.79752808988764949, 0.79752808988764949, 0.79752808988764949, 0.79752808988764949, 0.79752808988764949, 0.7975280898876494, 0.6966292134831461, 0.797752808988764, 0.8066292134831461, 0.797752808988764, 0.8066292134831461, 0.7977528089887649, 0.8066292134831461, 0.797752808988764, 0.8066292134831461, 0.797752808988764, 0.8066292134831461, 0.797752808988764, 0.8066292134831461, 0.797752808988764, 0.8066292134831, 0.8066292134831, 0.8066292134831, 0.8066292134831, 0.8066292134831, 0.8066292134831, 0.8066292134831, 0.8066292134831, 0.8066292134831, 0.8066292134831, 0.8066292134831, 0.8066292134831, 0.8066292134831, 0.8066292134831, 0.
```

```
def calc differences(lists rates):
      total differences = {}
      current differences = []
      local differences = []
      for x in range(len(lists rates)-1):
          for y in range(len(lists_rates)-1):
              for z in range(len(lists rates[y])):
                  if y >= x:
                      current differences.append(lists_rates[x][z] - lists_rates[y+1][z])
              if current differences not in local differences:
                  if current differences:
                      local differences.append(current differences)
              current differences = []
          total differences[x+1] = local differences
          local differences = []
      return total differences
  total differences = calc differences(lists rates)
✓ 0.2s
  print(total differences)
```

Array de diferenças:

```
{1: [[-0.1348314606741573, -0.1685393258426966, -0.11235955056179775, -0.0674157303370786, -0.0561797752808989, -0.235955056179775, -0.1348314606741573, -0.101123595505618, -0.0786516853932584, -0.1573033707865168, -0.0898876404494382, -0.1235955056179775, -0.1348314606741573, -0.101123595505618, -0.0786516853932584, -0.1573033707865168, -0.0898876404494382, -0.1235955056179775, -0.1348314606741573, -0.101123595505618, -0.02471910112359550561, -0.056797528089879, -0.0898876404494382, -0.1235955056179775, -0.1235955056179775, -0.033707865168, -0.05670529213483146, 0.011235955056179975, -0.0898876404494382, -0.0786516853932584, -0.1123595505617977, -0.1235955056179775, -0.0337078651685393, -0.1573033707865, -0.1235955056179775, -0.101123595505618, -0.0786516853932584, -0.0561797752808989, -0.1910112359550561, -0.1460674157303370786, -0.1235955056179775, -0.1235955056179775, -0.1235955056179775, -0.1235955056179775, -0.1235955056179775, -0.1235955056179775, -0.1235955056179775, -0.1235955056179775, -0.1235955056179775, -0.1235955056179775, -0.1235955056179775, -0.1235955056179775, -0.1235955056179775, -0.1235955056179775, -0.1235955056179775, -0.1235955056179775, -0.1235955056179775, -0.1235955056179775, -0.1235955056179775, -0.1235955056179775, -0.1235955056179775, -0.1235955056179775, -0.1235955056179775, -0.1235955056179775, -0.1235955056179775, -0.1235955056179775, -0.1235955056179775, -0.1235955056179775, -0.1235955056179775, -0.1235955056179775, -0.1235955056179775, -0.1235955056179775, -0.067415730337078676, -0.123595505617977, -0.06741573033707867168, -0.123595505617977, -0.123595505617977, -0.123595505617977, -0.123595505617977, -0.123595505617977, -0.123595505617977, -0.1235955056179775, -0.1235955056179775, -0.06741573033707865168, -0.1573033707865168, -0.1573033707865168, -0.1573033707865168, -0.1573033707865168, -0.1573033707865168, -0.1573033707865168, -0.1573033707865168, -0.1573033707865168, -0.1573033707865168, -0.1573033707865168, -0.1573033707865168, -0.1573033707865168, -0.1573033707865168, -0.
```

(b) Calcule o intervalo de confiança destas diferenças.

(c) Realize o teste de hipótese sobre estas diferenças para verificar se a diferença da taxa de acerto é significativamente maior entre as duas versões. Mostre sua conclusão para o teste.

Rejeita-se H0, pois o 0 não está no intervalo, portanto as médias de acerto dos classificadores são diferentes.

A primeira versão, com uma tabela a mais e mais informações, é maior do que a segunda versão.

(d) Calcule o intervalo de confiança da taxa de acerto para cada versão da base.

```
1 (0.7083788816487575, 0.7266772981265237)
2 (0.8252175672280455, 0.8399509720977969)
```

- (e) Realize o teste de hipótese de sobreposição dos intervalos de confiança. Mostre sua conclusão para o teste.
- 1 (0.7083788816487575, 0.7266772981265237)
- 2 (0.8252175672280455, 0.8399509720977969)
- 0.7266772981265237 < 0.8252175672280455

Não existe sobreposição, portanto a segunda versão tem um intervalo de confiança maior

3. (25 pontos) Qual o número máximo de características que podem ser removidas da base lris archive.ics.uci.edu/ml/datasets/iris sem reduzir significativamente a taxa de acerto? De na a metodologia utilizada para justificar sua resposta.

Não existe sobreposição entre os intervalos.

Se observarmos os intervalos de confiança, reduzindo 0 e 1 colunas, a taxa de acerto é bem próxima, já reduzindo 2 e por diante, a taxa de acerto cai drasticamente

```
1 (0.9392543625860171, 0.9514123040806496)
2 (0.917420609527016, 0.937690501584095)
3 (0.6997671170240668, 0.7286773274203776)
4 (0.5832407909731356, 0.6238703201379756)
```

4. (25 pontos) Utilizando o classificador *k*-NN na base Wine archive.ics.uci.edu/ml/datasets/ Wine, teste os valores *k* = 1, . . . , 15. Para qual valor de *k* o classificador apresenta uma taxa de acerto significativamente maior? De na a metodologia utilizada para justificar sua resposta.

O K-9 tem um intervalo de confiança maior, portanto uma taxa de acerto maior que todas as

outras.

```
int conf:
          1 (0.8278069811776297, 0.8590844045901608) 0.03127742341
int conf: 2 (0.7517376782081853, 0.7883372281588561) 0.03659954995
int conf: 3 (0.7871886077863689, 0.8240473472698112) 0.03685873948
int conf: 4 (0.7637935844656589, 0.7972551046729177) 0.0334615202
int conf: 5 (0.760634570546471, 0.7951706728992218) 0.03453610235
int conf: 6 (0.7450133992562152, 0.7785821063617623) 0.0335687071
int conf: 7 (0.742102976656216, 0.7755000195984655) 0.03339704294
∄t conf: 8 (0.7268687241753458, 0.7630189162740926) 0.03615019209
int conf: 9 (0.7221555790933124, 0.7602414246520058) 0.03808584555
int conf: 10 (0.7047592570220123, 0.7394354995322949) 0.03467624251
int conf: 11 (0.7006482820456401, 0.7345577104637231) 0.03390942841
int conf: 12 (0.6925011245518988, 0.7224801488563413) 0.0299790243
int conf: 13 (0.6855728748990733, 0.7204196344642229) 0.03484675956
int conf: 14 (0.670194082046534, 0.7058358805002827) 0.03564179845
int conf: 15 (0.6681356736485805, 0.7019017795349402) 0.03376610588
```